슬라이드 5 (Gaussian Blur) — 대본에 넣을 구체적 수치

- 초기 안정 구간: 원본 92.5% → σ=1 89.6% → σ=2 89.2% (거의 원본 수준 유지)
- 하락 시작: σ=4 84.6% → σ=8 78.8% (여기서 80% 기준선 최초 하회)
- 급락 구간: σ=16 67.5% → σ=32 53.3% → σ=64 45.0% (전체 실험 중 최저점)
- 이후 반등 아닌 정체: σ=128, σ=256 둘 다 49.6%로 소폭 반등 후 고정 (더 이상 떨어지지 않고 바닥에서 정체)
- ROC-AUC 동반 붕괴: 원본 0.9791 → σ=8 0.9147(0.9 붕괴) → σ=16 0.8487(0.8 붕괴) → σ=64 0.6496(최저)
- **클래스별 붕괴(가장 중요)**: Malignant 정확도 원본 98% → σ=16 66% → σ=32 25% → σ=64 11% → σ=128·σ=256 **0%**
- Confusion Matrix 근거: σ=256 에서 실제 Malignant 80 건 전부 오분류(Benign 21 건, Normal 59 건), Malignant 로 예측된 건 단 한 건도 없음
- Benign(84%)·Normal(65%)은 같은 조건에서 상대적으로 유지됨 → Malignant 만 선택적·완전 붕괴

슬라이드 6 (Block Encryption) — 대본에 넣을 구체적 수치

- 원본 92.9% → 256×256 92.5% (여기까지는 원본과 사실상 동일)
- 128×128 부터 이미 하락 시작: 88.3% → 64×64 86.7% (기존 대본 "128×128=92.9% 유지"는 오류, 정정 필요)
- 32×32 79.2% (80% 기준선 근접) → 16×16 72.5% → 8×8 73.3%(소폭 반등) → 4×4 61.7% → 2×2 55.4% → 1×1(픽셀 완전 셔플) 52.9%
- ROC-AUC: 원본 0.9804 → 32×32 0.9606(0.96 대 유지) → 16×16 0.9150(0.9 기준선턱걸이) → 4×4 0.7642(0.8 붕괴) → 1×1 0.6907
- **클래스별 반전 패턴(가장 중요)**: Malignant 는 원본 96% → 32×32 86% → 8×8 85% → 1×1 에서도 71% 유지 (거의 안 무너짐)
- 반대로 Normal 이 붕괴: 원본 90% → 8×8 48% → 4×4 31% → 2×2 10% → 1×1 **0%**
- Confusion Matrix 근거: 1×1 조건에서 실제 Normal 80 건 중 정확히 Normal 로 예측된 건 0 건(Benign 29 건, Malignant 51 건으로 오분류). 반면 실제 Malignant 80 건 중 57 건(71%)은 여전히 정확히 Malignant 로 분류

슬라이드 7 (비교/고찰)에 넣을 대비 포인트

- 트레이드오프 산점도: 원본·256×256·128×128·64×64 는 "고성능-저위험" 구역에 몰려 있고, 32×32 부터 완만히 이동, 4×4 이하부터 급격히 저성능 구역 진입
- **핵심 대비 문장**: "Blur 는 극단적 조건에서 암(Malignant)을 놓치는 방향으로 실패하고, Block Encryption 은 정상(Normal)을 암으로 오인하는 방향으로 실패한다" → 후자가 임상적으로 훨씬 안전 (위음성 대신 위양성 쪽으로 오류가 쏠림)
- 32×32 가 균형점이라는 기존 결론에 수치적 근거 추가: 정확도 79.2% + ROC-AUC 0.9606 을 동시에 확보하는 지점

Q1. Sigma=64에서 최저점(45.0%)을 찍고 128/256에서 49.6%로 반등하는 이유는?

A. 정보가 균질화되어서가 아니라, **클래스별 붕괴 시점이 어긋나면서 생기는 재가중 효과**입니다. Heatmap을 보면 σ=64에서 Malignant는 이미 11%로 거의 붕괴했는데 Normal은 82%로 멀쩡합니다. σ≥128에서는 모델이 Malignant 예측을 아예 포기(0%)하고 Benign(84%)·Normal 위주로만 찍기 시작하면서, 전체 평균이 오히려 소폭 오르는 겁니다. Block Encryption의 8x8(73.3%)이 16x16(72.5%)보다 높은 것도 같은 메커니즘이라 blur만의 특이 현상이 아니라 다중클래스 평균의 일반적 함정으로 설명하는 게 정확합니다.

Q2. 오버샘플링/augmentation 방식은? Data leakage 위험은 없나요?

A. 원본 케이스 ID 기준으로 먼저 train/test를 분리한 뒤, 각 그룹 내에서만 augmentation(회전·반전)을 적용했습니다. 따라서 동일 원본에서 파생된 augmented 이미지가 train과 test에 동시에 걸치는 일은 없으며, 이전에 발견했던 오버샘플링 관련 leakage(64.7% 오염) 문제와 달리 이 부분은 설계 단계에서 원천 차단했습니다.

Q3. Block Encryption과 Gaussian Blur의 보안 강도를 어떻게 동등하게 비교했나요?

A. 1:1로 강도를 매칭한 것이 아니라 각 기법을 독립적으로 스윕한 뒤 성능 기준선 도달 시점으로 비교했습니다. 80% 정확도 기준선은 Blur(σ=4, 84.6%)와 Block(64x64, 86.7%) 모두 4단계째에 하락하며 거의 동일하지만, ROC-AUC 0.9 기준선은 Blur가 5단계째(σ=8, 0.9147), Block이 6단계째(16x16, 0.9150)에 하락해 Block Encryption이 판별력을 한 단계 더 오래 유지합니다. 즉 원시 정확도 붕괴 속도는 비슷하지만 판별력 유지력은 Block이 근소하게 앞선다는 것이 데이터에 기반한 정확한 결론입니다.

Q4. Block Encryption에서는 Normal이 붕괴하고 Malignant는 견고한데, Blur에서는 반대로 Malignant가 붕괴하는 이유는?

A. Confusion Matrix에서 명확히 확인됩니다. 극단적 조건(Block 1x1, Blur σ=256)에서 완전히 대칭적인 패턴이 나타나는데, Block 1x1에서는 모델이 Normal을 예측값으로 단 한 번도 내놓지 않고(0), Blur σ=256에서는 반대로 Malignant를 단 한 번도 예측하지 않습니다(0). Block Encryption은 국소적 병변 텍스처는 보존하고 전역 공간배치만 흐트러뜨리므로 국소적으로 뚜렷한 Malignant 병변이 상대적으로 잘 보존되는 반면, Normal은 전역 조직 균일성으로 판단되기 때문에 공간배치가 깨지면 판단 근거가 사라집니다. Blur는 반대로 경계 정보를 직접 뭉개므로 경계가 핵심인 Malignant가 가장 먼저 타격을 받습니다.

Q5. 32×32(Block)/특정 sigma가 "최적의 균형점"이라는 결론이 이 데이터셋·모델에 한정되지 않나요?

A. 맞는 지적입니다. Tradeoff scatter에서 32x32가 고성능 클러스터와 저성능 클러스터 사이의 변곡점으로 뚜렷하게 나타나지만, 이는 EfficientNetV2-S와 폐 CT 데이터셋이라는 특정 조건의 결론입니다. 절대적 수치보다는 **"Block Encryption이 Blur보다 완만한 붕괴 곡선을 보인다"**는 상대적 경향성이 핵심 주장이며, 모델 범용성 검증(ResNet50, ViT 등)은 향후 연구로 계획되어 있습니다.

Q6. 비식별화 처리를 학습 단계에도 적용했나요, 아니면 원본으로 학습한 모델을 테스트만 비식별화했나요?

A. 각 조건(sigma, 블록 크기)별로 개별 학습을 진행했습니다. 이는 **"모델이 해당 왜곡 패턴에 적응할 기회가 있었던 상태의 성능"**을 의미하며, 실제 배포 환경에서 예고 없이 비식별화 이미지를 마주쳤을 때의 성능과는 다르다는 점을 한계로 명시할 필요가 있습니다.

오늘 실험에서 확인한 핵심은, Blur와 Block Encryption이 성능을 잃는 양상 자체가 정반대라는 점입니다.

Blur는 병변의 경계 정보를 직접 지우기 때문에 보안 수준이 높아질수록 악성 종양을 놓치는 방향으로 실패하는 반면, Block Encryption은 국소적인 병변 텍스처를 상대적으로 보존하기 때문에 가장 강한 조건에서도 악성 종양의 71%는 여전히 정확히 분류해내고, 대신 정상 소견을 과잉 의심하는 쪽으로 오류가 쏠립니다.

암을 놓치는 것보다 정상을 의심하는 실패가 임상적으로 훨씬 안전하다는 점에서, 저희는 Block Encryption을 실무에 적용 가능한 현실적 대안으로 보고 있습니다.

다만 오늘 질문 주신 것처럼, 32×32라는 균형점은 EfficientNetV2-S와 이번 데이터셋에 한정된 결과이고, 각 조건을 개별적으로 학습시켰기 때문에 실제 배포 환경과는 차이가 있을 수 있다는 한계도 분명히 인지하고 있습니다.

이를 보완하기 위해 ResNet50, ViT 등으로의 모델 범용성 검증과, 엣지 디바이스에서 첫 컨볼루션 단계만 처리해 특징 맵 형태로만 전송하는 분산 추론 구조를 Block Encryption과 결합하는 연구를 이어가고 있습니다.