EfficientNetV2-S 모델에서 개인정보 보호를 위한 영상 비식별화 기법의 성능 분석

2026 하계학술대회 · 곽윤석 · 김남기(교신저자) · 경기대학교 컴퓨터과학과

슬라이드 1. 표지

안녕하십니까. 경기대학교 컴퓨터과학과 곽윤석입니다.

오늘 발표할 주제는

'EfficientNetV2-S 모델에서 개인정보 보호를 위한 영상 비식별화 기법의 성능 분석'

입니다.

폐 CT 영상에 Gaussian Blur와 Block Encryption이라는 서로 다른 두 가지 비식별화 기법을 적용했을 때, EfficientNetV2-S 모델의 폐암 분류 성능이 각각 어떻게 달라지는지를 정량적으로 비교·분석한 연구입니다.

슬라이드 2. 서론 — 의료 AI와 보안의 충돌

먼저 연구의 출발점이 된 문제의식을 말씀드리겠습니다.

폐암은 조기에 발견할수록 생존율이 크게 높아지는 만큼, 폐암 조기 진단을 위한 AI 도입은 이제 선택이 아니라 필수적인 흐름이 되었습니다.

하지만 이러한 기술 발전과 동시에, 환자의 민감한 정보를 보호하기 위한 법적·제도적 규제 역시 갈수록 강화되고 있습니다. 이 지점에서 저희는 세 가지 문제를 발견했습니다.

첫째, 데이터 활용의 장벽입니다.

의료 데이터는 그 자체로 민감도가 매우 높기 때문에, 연구와 서비스 개발 전 과정에서 법적·윤리적 개인정보 보호 요구가 빠르게 늘고 있고, 이는 곧 데이터 접근과 활용의 장벽으로 이어집니다.

둘째, 성능 저하의 딜레마입니다.

개인정보를 지키기 위해 영상을 비식별화하면 진단 AI 의 정확도가 어느 정도 떨어질 수밖에 없는데, 정작 이 저하 폭이 구체적으로 얼마나 되는지에 대한 명확한 정량적 분석은 아직 부족한 실정입니다.

셋째, 이것이 바로 저희 연구가 지향하는 지점입니다.

본 연구는 보안성과 진단 정확도라는 상충하는 두 가치 사이의 균형점을 실험적으로 찾아내어, 실제 의료 AI 서비스 구축에 실질적으로 적용할 수 있는 기준을 제시하고자 했습니다.

슬라이드 3. 연구 배경 — 비식별화와 인공지능

이번 실험에 사용한 세 가지 핵심 구성 요소를 차례로 소개해 드리겠습니다.

첫 번째는 Gaussian Blur 입니다.

픽셀 값을 주변 픽셀과 평균화하여 영상을 흐리게 만듦으로써 정보를 가리는 가장 전통적인 비식별화 방식입니다.

구현이 간단하다는 장점이 있지만, 블러 강도가 세질수록 진단에 꼭 필요한 병변의 경계 정보까지 함께 지워질 위험이 있다는 점이 한계로 지적됩니다.

두 번째는 Block Encryption 입니다.

영상을 일정 크기의 블록 단위로 나눈 뒤, 그 블록들을 뒤섞어 전체적인 구조는 유지한 채 세부 내용만 알아볼 수 없게 만드는 방식입니다.

Blur 와 달리 영상의 공간적 맥락 정보가 어느 정도 남아 있기 때문에, AI 모델의 학습과 추론에 상대적으로 유리하다는 특징이 있습니다.

세 번째는 이번 실험의 분류 모델로 사용한 EfficientNetV2-S 입니다.

본 연구에서는 블록 암호화 9 단계, 블러 시그마 9 단계 등 총 20 여 가지에 이르는 비식별화 조건을 각각 학습·평가해야 했기 때문에, 무엇보다 연산 효율성과 학습 속도가 중요한 선택 기준이었습니다.

EfficientNetV2-S 는 기존 합성곱 신경망 대비 적은 파라미터와 연산량으로도 높은 분류 정확도를 확보할 수 있는 경량 구조로, 다수의 실험 조건을 반복적으로 스윕(sweep)해야 하는 본 연구의 실험 설계에 특히 적합했습니다.

또한 점진적 학습(Progressive Learning) 방식을 채택하고 있어, 학습 초반에는 낮은 해상도와 약한 정규화로 빠르게 학습하고 후반으로 갈수록 해상도와 정규화 강도를 함께 높여가는 방식으로 학습 효율과 일반화 성능을 동시에 확보합니다.

이러한 특성 덕분에 학습 시간을 크게 단축하면서도, 의료 영상과 같이 미세한 패턴 인식이 중요한 분류 과제에서도 안정적인 성능을 보였습니다.

슬라이드 4. 실험 설계 — 정밀한 비교 분석

실험 설계는 크게 데이터셋 구성과 실험 변수 통제, 두 부분으로 이루어져 있습니다.

먼저 데이터셋 구성 측면입니다.

폐 CT 영상은 미세한 병변까지 놓치지 않도록 512×512 의 높은 해상도로 촬영된 데이터를 사용했으며, Benign(양성), Malignant(악성), Normal(정상)의 세 가지 클래스로 정밀하게 분류하여 실험을 진행했습니다.

원본 데이터는 양성 120 장, 악성 561 장, 정상 416 장으로 클래스 간 수량 편차가 컸기 때문에, 특정 클래스에 편향된 학습이 이루어지지 않도록 각 클래스를 1,000 장씩으로 오버샘플링하여 클래스 간 균형을 맞춘 뒤 실험에 활용했습니다.

다음으로 실험 변수 통제 측면입니다.

두 비식별화 기법 모두 512×512 크기의 동일한 원본 영상을 기준으로, 처리 강도를 단계적으로 조정하며 성능이 무너지는 지점을 정밀하게 탐색했습니다.

Block Encryption 의 경우, 원본 영상을 지정한 블록 크기 단위로 균등하게 분할한 뒤 그 블록들의 위치를 뒤섞는 방식으로 비식별화를 수행했습니다.

예를 들어 블록 크기를 256×256 으로 설정하면 영상은 2×2, 총 4 개의 블록으로 나뉘어 서로 뒤섞이고, 블록 크기가 작아질수록 분할되는 블록의 개수는 기하급수적으로 늘어납니다.

이러한 방식으로 256×256 에서 128×128, 64×64, 32×32, 16×16, 8×8, 4×4, 2×2 를 거쳐 최종적으로 1×1, 즉 픽셀 단위로 완전히 섞이는 조건까지 총 열 단계로 세분화하여 실험을 진행했습니다.

블록 크기가 작아질수록 원본 영상이 지니고 있던 공간적 구조와 맥락 정보가 점진적으로 소실되며, 이를 통해 보안 수준과 진단 성능 사이의 관계를 단계별로 정밀하게 관찰할 수 있었습니다.

Gaussian Blur 의 경우에는 동일한 원본 영상에 적용하는 블러 커널의 표준편차, 즉 시그마 값을 0 에서부터 256 까지 점진적으로 증가시키는 방식으로 실험을 설계했으며, 시그마 값이 커질수록 각 픽셀이 주변의 더 넓은 영역과 평균화되면서 영상 전체의 흐림 정도가 강해지고, 원본 대비 정보 손실이 점차 누적되는 구조입니다.

두 기법 모두 단일 조건이 아닌 다단계 실험으로 설계한 이유는, 성능이 급격히 무너지는 임계점을 정확히 포착하고 두 기법이 보안 강도에 따라 서로 다른 붕괴 양상을 보인다는 점을 곡선 형태로 비교하기 위함이었습니다.

아울러 EfficientNetV2-S 모델을 기준으로 학습률, 배치 크기 등 하이퍼파라미터를 모든 조건에서 동일하게 고정함으로써, 비식별화 기법 자체가 성능에 미치는 순수한 영향만을 측정할 수 있도록 공정한 비교 환경을 구축했습니다.

슬라이드 5. Gaussian Blur의 한계 분석

먼저 Gaussian Blur 의 한계 분석 결과를 말씀드리겠습니다.

결과는 크게 세 단계로 나누어 살펴볼 수 있습니다.

첫 번째는 초기 성능 유지 구간입니다.

원본 92.5 퍼센트 대비 시그마 1 과 2 구간에서는 각각 89.6 퍼센트, 89.2 퍼센트로 원본과 큰 차이 없이 진단 가치를 안정적으로 유지하는 모습을 보였습니다.

두 번째는 임계점에서의 붕괴입니다.

시그마 4 에서 84.6 퍼센트, 시그마 8 에서 78.8 퍼센트로 80 퍼센트 기준선 아래로 떨어지기 시작했고, 이후 시그마 16 에서 67.5 퍼센트, 시그마 32 에서 53.3 퍼센트, 시그마 64 에서는 45.0 퍼센트까지 급락하며 최저점을 기록했습니다.

이러한 정확도 하락은 모델의 변별력을 나타내는 ROC-AUC 지표에서도 동일하게 관찰되었는데, 원본 0.9791 에서 시그마 8 에 0.9147 로 0.9 기준선을 하회하고, 시그마 16 에서는 0.8487 로 0.8 기준선마저 무너지는 모습을 보여, 정확도와 변별력이 함께 붕괴되는 양상을 확인할 수 있었습니다.

세 번째는 이번 실험에서 가장 주목할 만한 결과인 클래스별 붕괴 양상입니다.

클래스별로 나누어 보면, 악성(Malignant) 종양의 분류 정확도가 원본 98 퍼센트에서 시그마 16 에 66 퍼센트, 시그마 32 에 25 퍼센트, 시그마 64 에 11 퍼센트로 급격히 무너지다가, 시그마 128 과 시그마 256 에서는 급기야 0 퍼센트를 기록했습니다.

Confusion Matrix 로 확인한 결과, 가장 강한 블러 조건에서는 실제 악성 종양 사례가 단 한 건도 악성으로 예측되지 못하고 전부 양성 또는 정상으로 오분류되었습니다.

이는 단순한 정확도 하락을 넘어, 강한 블러가 AI 로 하여금 실제 암을 암으로 진단하지 못하게 만드는 임상적으로 매우 위험한 실패 양상이라는 점에서, Gaussian Blur 는 개인정보 보호 수준이 높아질수록 의료 AI 진단 모델에 활용하기에는 적합하지 않은 기법이라는 점을 명확히 확인할 수 있었습니다.

슬라이드 6. Block Encryption의 압도적 안정성

다음은 Block Encryption 의 결과입니다.

이 기법은 크게 세 가지 특징으로 요약할 수 있습니다.

첫 번째는 원본 수준의 성능 재현입니다.

원본 92.9 퍼센트, 256×256 블록에서 92.5 퍼센트로 초기 구간은 원본과 거의 다름없는 정확도를 유지했으며, 128×128 에서는 88.3 퍼센트, 64×64 에서는 86.7 퍼센트로 완만하게 하락하는 모습을 보였습니다.

두 번째는 점진적 성능 저하 특성입니다.

32×32 블록에서는 79.2 퍼센트로 80 퍼센트 기준선에 근접한 수준을 유지했고, 블록이 더 작아진 16×16 에서 72.5 퍼센트, 8×8 에서 73.3 퍼센트, 4×4 에서 61.7 퍼센트로 이어지며, 가장 강한 보안 수준인 1×1 블록에서도 52.9 퍼센트를 지켜내 완전히 무너지지 않았습니다. ROC-AUC 역시 원본 0.9804 에서 32×32 까지 0.96 대를 유지하고, 16×16 에서 0.9150 으로 0.9 기준선을 지켰으며, 1×1 에서도 0.6907 을 기록해 Gaussian Blur 대비 훨씬 완만한 하락 곡선을 보였습니다.

세 번째는 이번 실험에서 가장 흥미로운 발견인, Gaussian Blur 와는 정반대 방향의 클래스별 붕괴 양상입니다.

Block Encryption 에서는 악성(Malignant) 클래스가 보안 수준이 아무리 높아져도 끝까지 견고하게 유지되었습니다.

원본 96 퍼센트에서 1×1 블록에서도 71 퍼센트를 유지하며 상대적으로 완만하게 하락한 반면, 오히려 정상(Normal) 클래스가 원본 90 퍼센트에서 8×8 에 48 퍼센트, 4×4 에 31 퍼센트, 2×2 에 10 퍼센트, 1×1 에서는 0 퍼센트까지 무너졌습니다.

Confusion Matrix 로 확인한 결과, 완전 암호화 조건에서 실제 정상 소견 80 건 중 정상으로 올바르게 예측된 사례는 단 한 건도 없었던 반면, 실제 악성 종양 80 건 중에서는 57 건, 약 71 퍼센트가 여전히 악성으로 정확히 분류되었습니다.

이는 Block Encryption 이 보안 수준을 극한까지 높이더라도 암을 놓치는 위양성 누락(false negative) 위험은 낮게 유지하고, 대신 정상 소견을 과잉 의심하는 방향으로 오류가 치우친다는 것을 보여주며, 임상적으로 훨씬 안전한 실패 양상이라는 점에서 의미가 큽니다.

슬라이드 7. 결과 고찰 — 보안과 성능의 조화

두 기법의 결과를 함께 놓고 비교하면, 성능이 떨어지는 궤적 자체가 근본적으로 다르다는 점을 확인할 수 있습니다.

먼저 궤적의 차이입니다.

지수적으로 급격히 무너지는 Gaussian Blur 와 달리, Block Encryption 은 보안 수준이 높아져도 완만하고 안정적인 곡선을 그리며 성능이 저하됩니다.

보안성과 정확도를 함께 놓고 본 트레이드오프 분석에서도, 원본과 256×256, 128×128, 64×64 조건은 고성능·저위험 구역에 안정적으로 위치했고, 32×32 부터 완만하게 저성능 방향으로 이동했으며, 4×4 이하에서야 비로소 급격한 성능 저하 구역으로 진입하는 모습을 보였습니다.

다음으로 보안의 재정의입니다.

Block Encryption 은 고보안 구역에서도 성능을 크게 잃지 않을 뿐 아니라, 앞서 살펴본 것처럼 보안 수준이 극단적으로 높아져도 악성 종양을 놓치지 않는 방향으로 오류가 발생한다는 점에서, 단순히 "정확도를 덜 잃는다"는 차원을 넘어 임상적으로 더 안전한 실패 양상을 보인다고 할 수 있습니다.

마지막으로 최적의 솔루션입니다.

이번 실험을 통해 32×32 블록 크기가 80 퍼센트에 근접한 정확도와 0.96 수준의 ROC-AUC 를 동시에 유지하면서 보안성도 상당 수준 확보할 수 있는 균형점, 즉 실무에 적용 가능한 기준점이 될 수 있음을 확인했습니다.

슬라이드 8. 결론 — 안전한 의료 AI의 미래

결론적으로, Block Encryption 은 프라이버시 보호와 의료 AI 혁신이라는 두 가치를 동시에 지킬 수 있는 가장 현실적인 대안이라고 판단됩니다.

이를 바탕으로 저희는 다음 네 가지 방향으로 후속 연구를 진행하고 있거나 계획하고 있습니다.

첫째, 풀링 실험과 지표 수식화입니다.

Pooling 기법에 따른 성능 차이를 실험하면서, 보안성과 정확도를 함께 나타낼 수 있는 통합 평가 지표를 수식으로 정립하는 작업을 현재 진행하고 있습니다.

둘째, 모델 범용성 검증입니다.

ResNet50, ViT 등 다른 딥러닝 모델에도 동일한 실험을 적용하여, 이번 연구에서 얻은 결과가 특정 모델에 국한되지 않고 일반적으로 성립하는지 검증할 계획입니다.

셋째, 분산 추론 시스템 구축입니다.

현재 저희는 ResNet50 의 첫 번째 컨볼루션 단(stem 단계)을 전체 네트워크에서 분리하여, 엣지 디바이스에서 이 초기 단계만 수행하고 이후 단계는 클라우드로 넘기는 구조를 실험하고 있습니다.

이렇게 첫 컨볼루션 단만 엣지에서 처리하면, 원본 영상 자체는 엣지 단에서 특징 맵(feature map) 형태로 이미 변환된 뒤에만 외부로 전송되기 때문에, 사람이 육안으로 식별 가능한 원본 이미지가 네트워크를 통해 클라우드로 넘어갈 필요가 없어집니다.

즉 비식별화 기법과는 별개로, 모델 구조 자체를 분할하는 것만으로도 민감한 원본 데이터의 유출 경로를 원천적으로 차단할 수 있다는 것이 이 접근의 핵심입니다.

앞으로는 엣지에서 처리할 레이어의 범위를 어디까지 확장하는 것이 연산 부담과 보안성 사이에서 가장 효율적인지 검증하고, 이를 앞서 다룬 Block Encryption 기반 비식별화와 결합하여, 엣지와 클라우드를 연계한 이중 보안 구조의 분산 추론 시스템으로 발전시켜 나갈 계획입니다.

넷째, 실시간 최적화입니다.

고해상도 영상도 지연 없이 즉시 비식별화하고 진단할 수 있도록 전체 처리 속도를 높이는 방향으로 연구를 이어가고자 합니다.

슬라이드 9. Q&A

이상으로 발표를 마치겠습니다.

본 연구는 정부(과학기술정보통신부) 재원으로 정보통신기획평가원의 학·석사연계 ICT 핵심인재양성사업 지원과, 2024 년도 정부(교육부) 재원으로 한국연구재단의 지원을 받은 기초연구사업의 일환으로 수행되었습니다.

경청해 주셔서 감사합니다.

질문 있으시면 편하게 말씀해 주시기 바랍니다.